2 CHCĘTE TREŚCI:

JAK KOMPUTER ROZPOZNAJE KOTA?

SZTUCZNA SIEĆ NEURONOWA

Od liczb w obrazie do uczenia na przykładach.

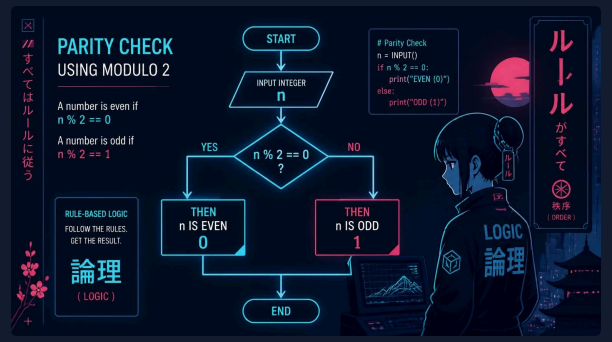
DANE | WAGI | UCZENIE



Made with GAMMA

DWA SPOSOBY PROGRAMOWANIA

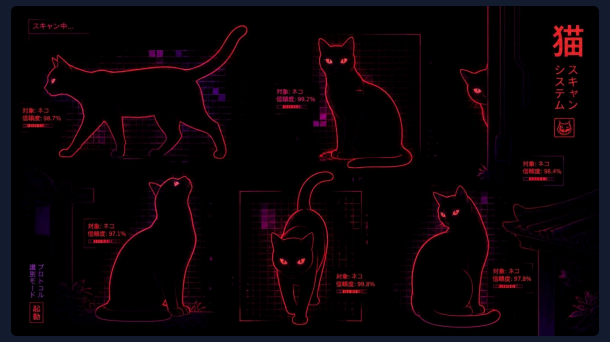
OD REGUŁ DO UCZENIA NA PRZYKŁADACH



TRADYCYJNY KOD

Zwykły Program

Programista zapisuje sztywne reguły (np. reszta z dzielenia przez 2 sprawdza parzystość). Komputer wykonuje instrukcje krok po kroku.



WYZWANIE

Rozpoznawanie Kota

Różne kolory, pozy, zasłonięcia i oświetlenie. Nie da się opisać kota kompletnym zestawem ręcznych reguł.



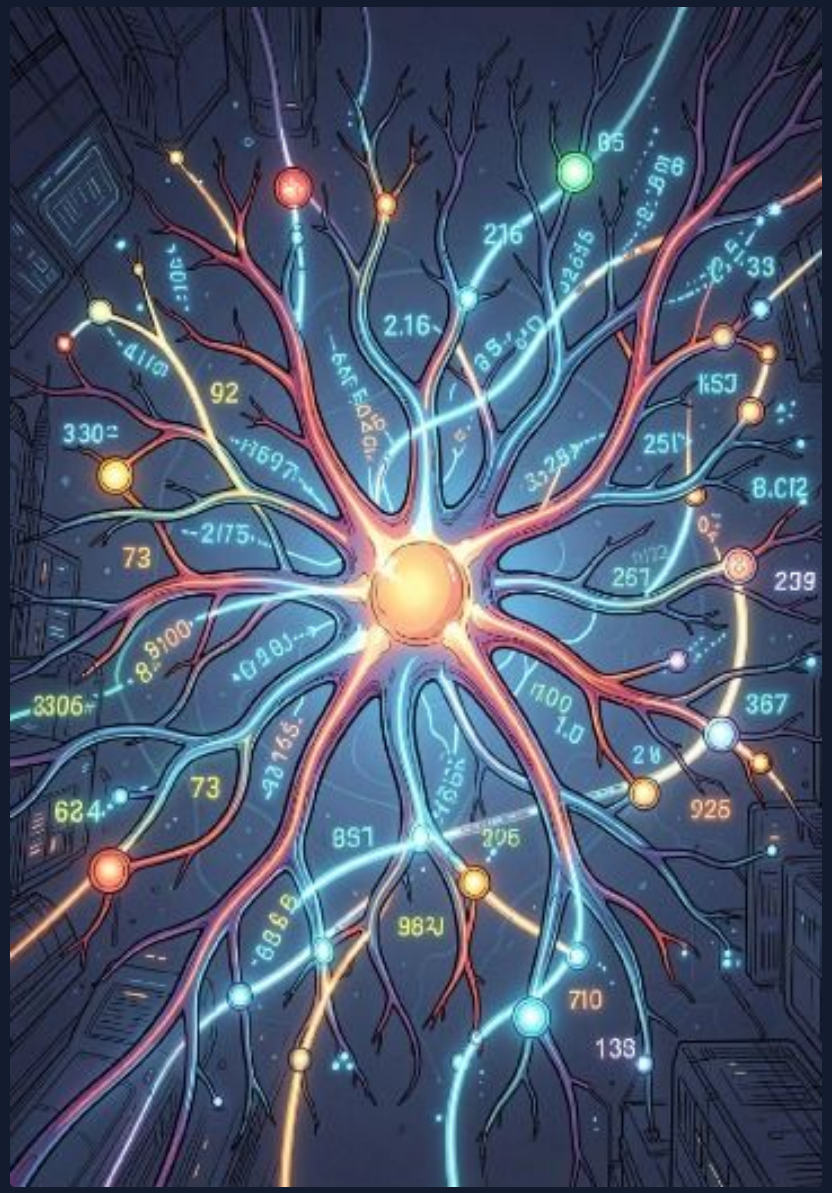
NOWY PARADYGMAT

Uczenie Maszynowe

Pokazujemy wiele przykładów z etykietami („kot”, „pies”). Model sam dostosowuje swoje parametry do danych.

Made with GAMMA

CZYM JEST SZTUCZNA SIEĆ NEURONOWA?



Model matematyczny, nie myślący mózg

1

Neuron Biologiczny

Odbiera sygnały chemiczno-elektryczne i przekazuje impulsy dalej. Działa w żywym organizmie jako część tkanki nerwowej.

2

Neuron Sztuczny

Mnoży liczby przez wagi, sumuje je i stosuje matematyczną funkcję aktywacji. Połączone neurony tworzą warstwy.

3

Optymalizacja

Sieć nie „myśli" jak człowiek. Mózg jest jedynie inspiracją dla struktury - w praktyce to czysta optymalizacja liczbowa.

Made with GAMMA

WEJŚCIE MODELU

DLA SIECI NEURONOWEJ, OBRAZ TO TABLICA LICZB



Z bliska obraz składa się z pikseli.

Zdjęcie to tablica pikseli. Każdy piksel zapisujemy liczbami, na przykład trzema składowymi RGB: czerwoną, zieloną i niebieską.

OBRAZ 100×100 RGB

30 000

wartości na wejściu

$$100 \times 100 \times 3 = 30\,000$$

Tekst również zamieniamy na liczby: tokeny i wektory. Dźwięk można przedstawić jako spektrogram.

Made with GAMMA

WEWNĄTRZ NEURONU

NEURON LICZY SUMĘ WAŻONĄ PLUS BIAS

$$z = x_1 w_1 + x_2 w_2 + \ldots + b$$

Wagi sterują wpływem wejść

Waga dodatnia zachowuje znak sygnału (wzmacnia go, gdy jest większa od 1), ujemna odwraca znak, zero wyłącza wejście

Bias przesuwa próg

Jest dodawany do sumy i zmienia moment, w którym neuron się aktywuje.

To jeszcze nie jest końcowy wynik neuronu.

Made with GAMMA

OD SUMY DO SYGNAŁU

FUNKCJA AKTYWACJI DAJE SIECI NIELINIOWOŚĆ

Funkcja aktywacji bierze sumę z neuronu i decyduje, jaki sygnał wyśle dalej.

$$\mathrm{ReLU}(z) = \max(0, z)$$



ReLU zeruje wartości niedodatnie; dodatnie przepuszcza bez zmian.

Przekształcenie z

Funkcja aktywacji pobiera sumę z z neuronu i decyduje, jak silny sygnał przesłać do kolejnej warstwy.

Przykład: *Funkcja ReLU*

Wynik ujemny lub równy 0 zamienia na 0. Wynik dodatni przepuszcza bez zmian.

Rola Nieliniowości

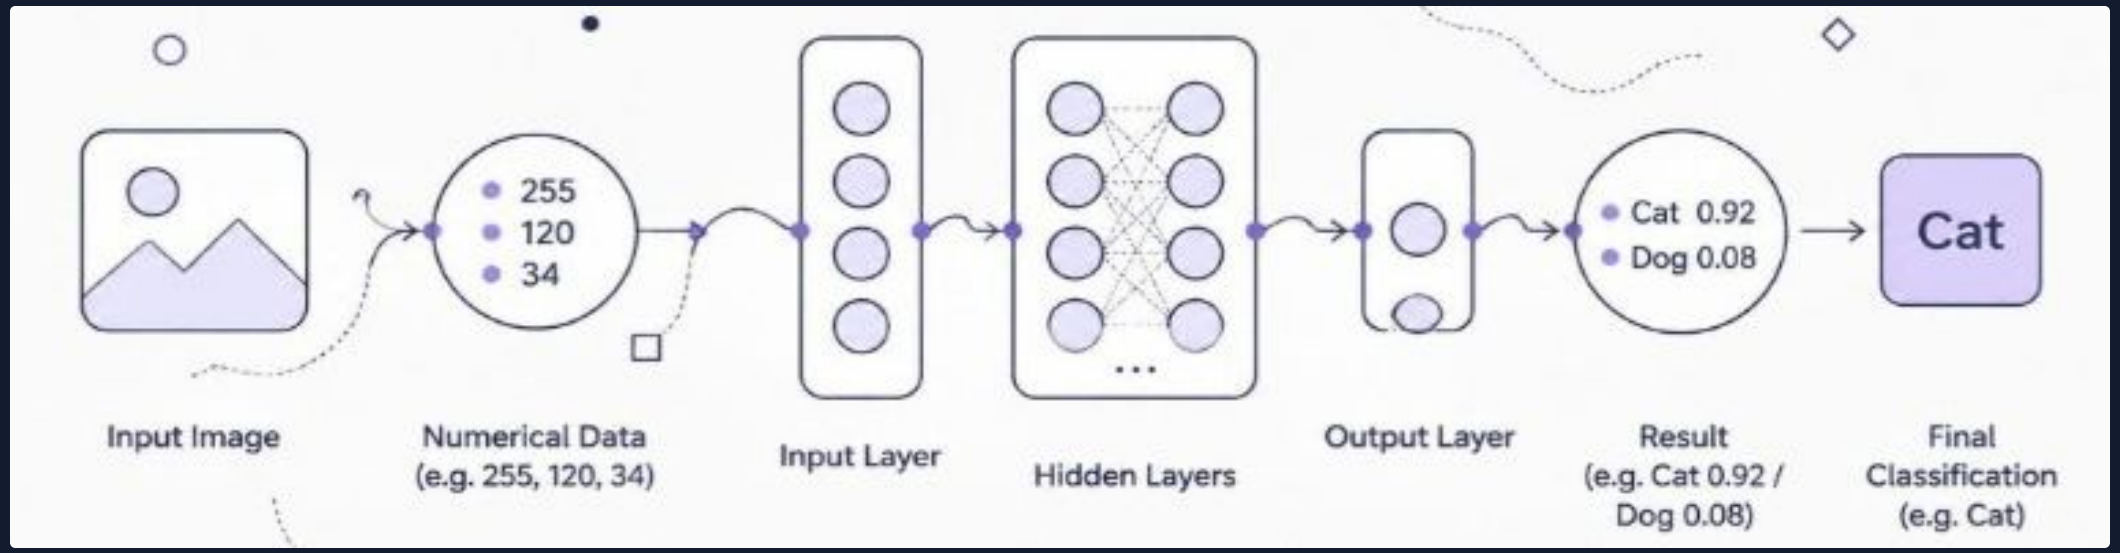
Bez nieliniowości cała wielowarstwowa sieć zwinęłaby się do prostej operacji liniowej.

Made with GAMMA

PROPAGACJA W PRZÓD

PRZEPŁYW DANYCH PRZEZ WARSTWY

W sieci rozpoznającej obrazy kolejne warstwy mogą łączyć proste sygnały w coraz bardziej złożone cechy.
Pojedynczy neuron liczy prosto. Rozpoznawanie wynika ze współpracy wielu neuronów.
Sieci mogą mieć miliony parametrów, a warstw bywa od kilku do kilkuset.



WARSTWA WEJŚCIOWA

Piksele

Surowe liczby wprowadzone do modelu.

WARSTWY UKRYTE

Krawędzie

Detekcja prostych linii i kontrastów.

WARSTWY UKRYTE

Kształty

Łączenie linii w oczy, uszy i pyszczek.

WARSTWA WYJŚCIOWA

Klasyfikacja

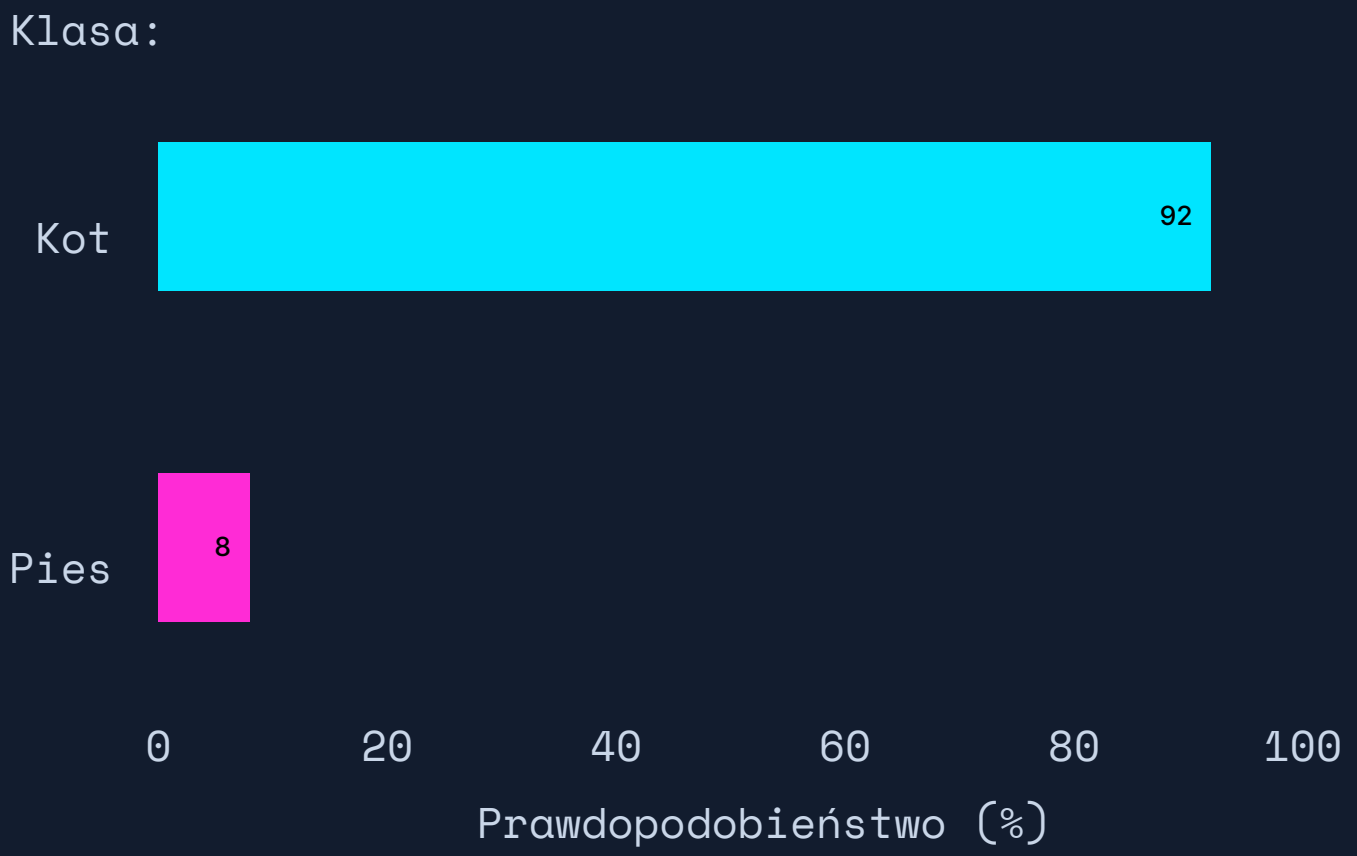
Kombinacja cech wskazująca na „kota”

Made with GAMMA

INTERPRETACJA WYJŚCIA

WARSTWA WYJŚCIOWA: WYNIK SIECI

Warstwa wyjściowa daje po jednej liczbie na klasę, na przykład 3,7; −1,2; 0,05. Nie są jeszcze prawdopodobieństwami, więc zamieniamy je na procenty, które sumują się do 100%. Przykład dla dwóch klas: kot 0,92, pies 0,08.



92%

Model wskazuje kota

Potocznie: „sieć w 92% pewna, że to kot”. To ocena modelu, a nie gwarancja poprawności.

Ten dwuklasowy przykład nie jest przeliczeniem trzech surowych wyników powyżej.

Made with GAMMA

DOSTRAJANIE PARAMETRÓW

PEŁNY CYKL UCZENIA SIĘ

1. DANE

Otrzymuje dane z etykietami.



2. PROPAGACJA W PRZÓD

Sieć otrzymała już dane wejściowe i generuje wstępne przewidywania.

3. FUNKCJA STRATY

Funkcja straty określa liczbowo różnicę między przewidywaniami sieci a rzeczywistą etykietą.

4. PROPAGACJA WSTECZNA

Błąd jest "rozprzestrzeniany" wstecz, aby obliczyć gradienty,

5. OPTYMALIZATOR

Wykorzystuje gradienty do korekty wag i biasów, minimalizując przyszłe błędy.

Cykl może powtarzać się miliony razy.
Sieć sama uczy się wag: po korekcie ponownie przewiduje odpowiedź i mierzy błąd.

Made with GAMMA

PRZYPISANIE ODPOWIEDZIALNOŚCI

PROPAGACJA WSTECZNA OBLICZA GRADIENTY

Gradienty to liczbowe określenie „udziału w winie” poszczególnych wag.

ANALOGIA

Przesolona Zupa

Kucharz cofa się od efektu do przyczyn (bulion, przyprawy, czas itp.).

UDZIAŁ W BŁĘDZIE

Gradienty

Obliczenie, jak każda waga i bias przyczyniły się do pomyłki.

WAŻNA UWAGA

Tylko Obliczenia

Propagacja wsteczna sama nie zmienia wag - wyznacza jedynie kierunek zmian.

Made with GAMMA

PROPAGACJA WSTECZNA – JAK USTALIĆ, CO POPRAWIĆ?

Propagacja wsteczna to mechanizm, który pozwala sieci zrozumieć, które z jej wewnętrznych parametrów (wag i biasów) są odpowiedzialne za błąd w przewidywaniach, a następnie je skorygować.

1 Błąd na wyjściu

Po propagacji w przód, sieć porównuje wynik z oczekiwaną odpowiedzią i oblicza globalny błąd.

2 Powrót warstwami

Błąd jest "rozprzestrzeniany" wstecz, od warstwy wyjściowej, przez ukryte, aż do wejściowej.

3 Obliczenie gradientów

Dla każdej wagi i biasu obliczamy "udział winy", czyli gradient – jak bardzo zmiana danego parametru wpływa na błąd.

4 Aktualizuj parametry

Wagi i biasy są korygowane w kierunku, który minimalizuje błąd, przygotowując sieć do kolejnej iteracji uczenia.

Propagacja wsteczna pozwala sieci neuronowej na ciągłe samodoskonalenie, ucząc się coraz bardziej złożonych wzorców z danych

Made with GAMMA

OCENA JAKOŚCI

CZY SIEĆ NAPRAWDĘ SIĘ NAUCZYŁA?

BŁĄD 1

Overfitting

Wykucie danych na pamięć. Słabe wyniki na nowych przykładach.

BŁĄD 2

Underfitting

Zbyt prosta sieć lub za krótki trening. Brak zrozumienia danych.

CEL

Generalizacja

Poprawne rozpoznawanie zupełnie nowych obiektów.

Made with GAMMA