Sztuczna sieć neuronowa — cały proces od początku do końca

Cel: połączyć wszystkie elementy prezentacji w jeden spójny przykład. Przykład: rozpoznawanie kota na zdjęciu

Wejście

Zdjęcie zamienia się w wartości liczbowe — piksele RGB.



Przetwarzanie

Warstwy mnożą wejścia przez wagi, dodają bias i stosują aktywację.



Wynik

Warstwa wyjściowa zwraca prawdopodobieństwa klas, np. „kot” i „pies”.



Uczenie

Strata mierzy błąd, a propagacja wsteczna i optymalizator poprawiają wagi.



Testowanie

Sprawdzamy, czy sieć dobrze rozpoznaje także nieznane wcześniej obrazy.

Made with GAMMA

Sztuczna sieć neuronowa — cały proces od początku do końca

Podsumujmy kluczowe etapy, które pozwalają sieci neuronowej uczyć się i podejmować decyzje.

Wejście

Dane (np. obraz) są zamieniane na liczbowe wartości (piksele RGB), które sieć może przetwarzać.

Przetwarzanie

W kolejnych warstwach neurony wykonują obliczenia: mnożą wejścia przez wagi, sumują je z biasem i aktywują.

Wynik

Warstwa wyjściowa generuje prawdopodobieństwa przynależności do różnych klas, np. "kot" 0.92, "pies" 0.08.

Uczenie

Na podstawie błędu (straty) sieć aktualizuje swoje wagi i biasy za pomocą propagacji wstecznej i optymalizatora.

Testowanie

Sprawdzamy, jak sieć radzi sobie z nowymi, nigdy wcześniej niewidzianymi danymi, oceniając jej zdolność do generalizacji.

Made with GAMMA

Typy Zadań Sieci Neuronowych: Klasyfikacja vs Regresja

Do tej pory nasza sieć neuronowa odpowiadała na pytanie: **„co to jest?”** (kot czy pies). To jest zadanie **klasyfikacji**: sieć wybiera jedną z kilku gotowych kategorii.

Ale sieci neuronowe potrafią również odpowiadać na pytanie: **„ile?”** albo **„jaka wartość?”**. Nazywamy to **regresją**.

1

Klasyfikacja

Celem jest przypisanie danych do jednej z predefiniowanych kategorii.

- Rozpoznawanie obrazów (kot/pies)
- Wykrywanie spamu (spam/brak spamu)
- Diagnoza choroby (chory/zdrowy)

2

Regresja

Celem jest przewidywanie ciągłej wartości liczbowej.

- Przewidywanie ceny mieszkania
- Prognoza temperatury na jutro
- Szacowanie, ile klient wyda w przyszłości

Budowa sieci jest bardzo podobna w obu przypadkach. Różni się głównie warstwa wyjściowa i funkcja straty (sposób mierzenia błędu).

Klasyfikacja odpowiada „co to jest”, regresja odpowiada „ile”. To dwa najczęstsze typy zadań rozwiązywanych przez sieci neuronowe.

Made with GAMMA

Ograniczenia sieci neuronowych

Sieci neuronowe to potężne narzędzia, ale mają swoje ograniczenia, o których warto pamiętać.



Zapotrzebowanie na dane

Wymagają ogromnych zbiorów danych treningowych (tysiące, miliony przykładów), podczas gdy człowiek uczy się na niewielu.



Brak wyjaśnialności

Często nie potrafią uzasadnić swoich decyzji ("czarna skrzynka"), co jest problemem w krytycznych zastosowaniach (np. medycyna).



Pewność, która myli

Wysokie prawdopodobieństwo wyniku nie oznacza jego bezwzględnej poprawności, zwłaszcza w obliczu nowych, nieznanych danych.



Brak rozumowania

Nie mają wiedzy o świecie ani logicznego myślenia; ich "inteligencja" sprowadza się do optymalizacji liczbowej.

Wniosek: sieci neuronowe są skuteczne w konkretnych, dobrze zdefiniowanych zadaniach. Nie zastępują jednak myślenia ani odpowiedzialności człowieka.

Made with GAMMA



Mini-batch — nauka w porcjach

Wyobraź sobie, że musisz nauczyć się z podręcznika liczącego 10 000 stron. Możesz przeczytać go w całości i dopiero wtedy zacząć ćwiczyć. Możesz też ćwiczyć po każdej pojedynczej stronie. Albo możesz przeczytać rozdział, poćwiczyć, przeczytać kolejny — i tak dalej.

1. Cały podręcznik na raz

Nauka na całym zbiorze danych naraz wymagałaby ogromnej pamięci i byłaby nieefektywna.

2. Jedna strona na raz

Uczenie się po jednym przykładzie prowadzi do skokowych i niestabilnych aktualizacji wag.

3. Rozdział po rozdziale (Mini-batch)

Najbardziej rozsądne podejście: dzielimy dane na małe porcje (np. 32-64 przykłady), na których sieć uczy się stopniowo.

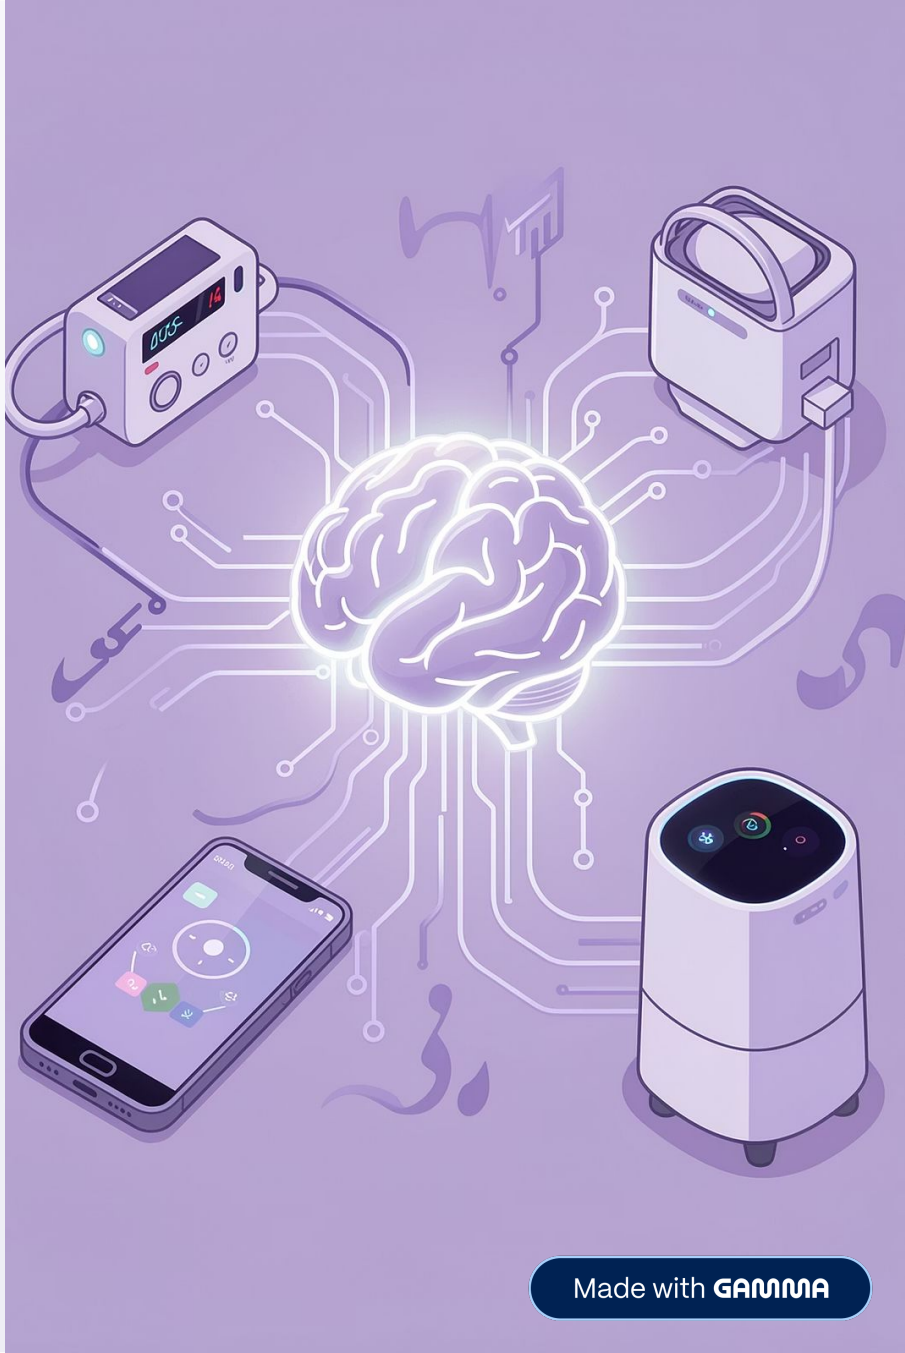
Sieć przetwarza jedną porcję, aktualizuje wagi, przechodzi do kolejnej. Jedno pełne przejście przez wszystkie porcje danych to jedna epoka. Mini-batch to praktyczny kompromis: wystarczająco dużo przykładów, żeby aktualizacja wag była sensowna, i wystarczająco mało, żeby proces był szybki i stabilny.

Made with GAMMA

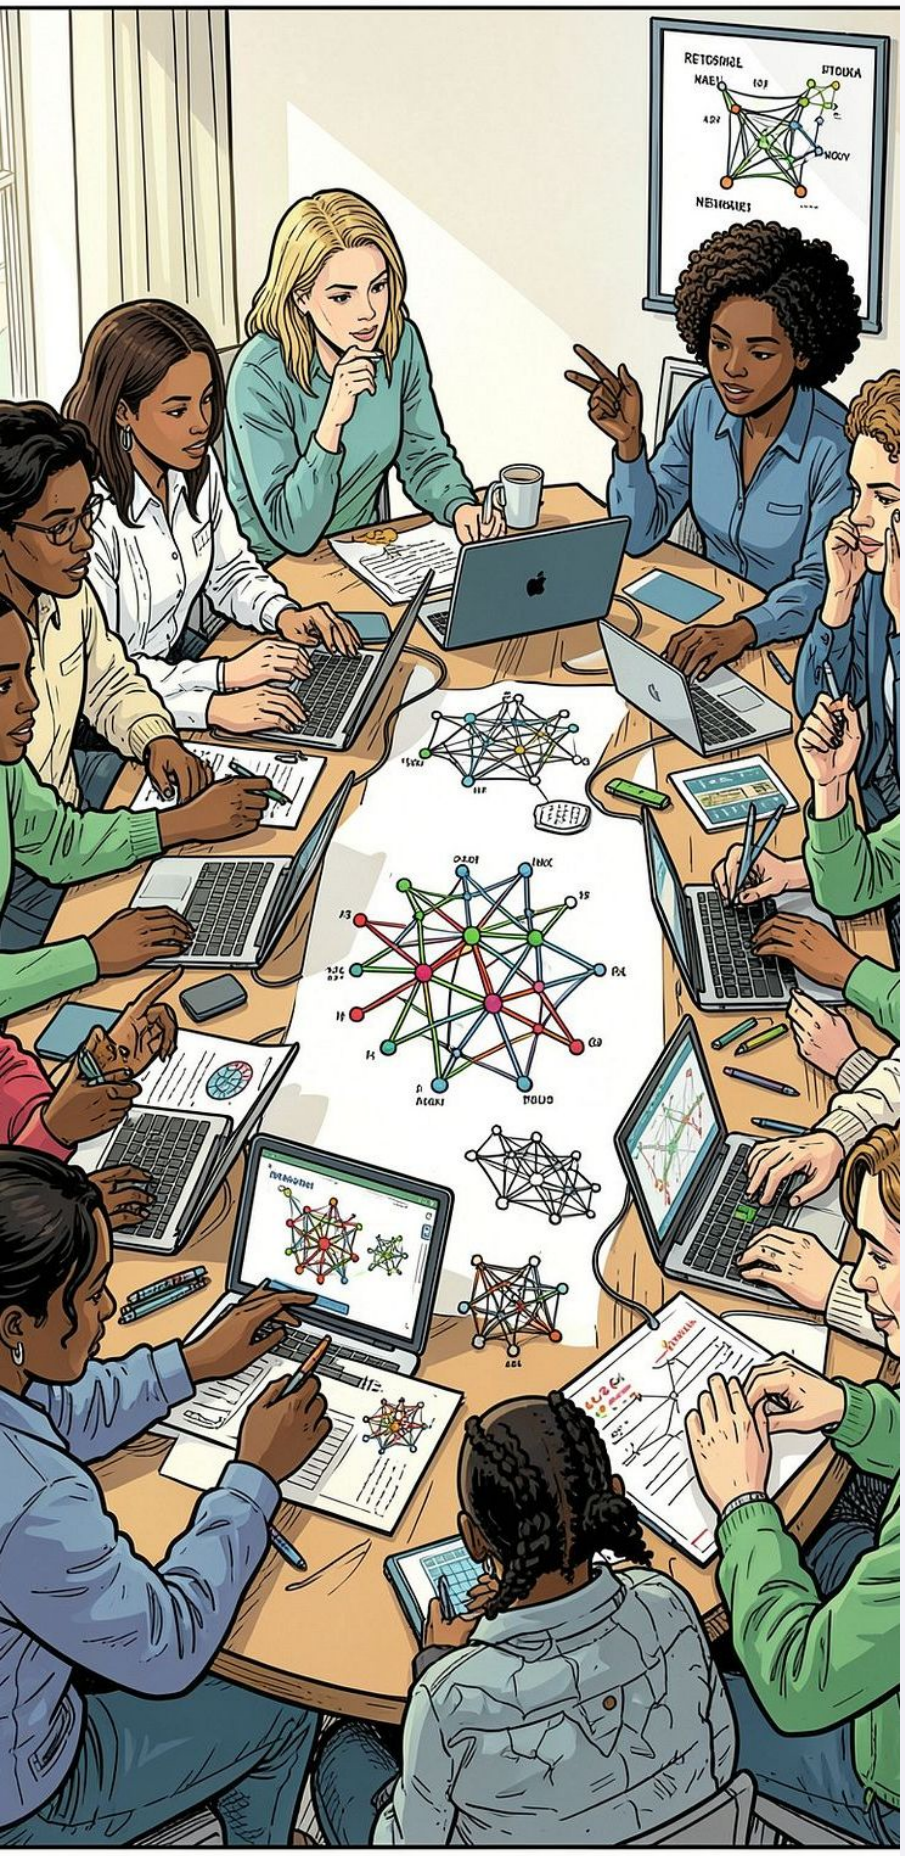
Co się dzieje z wytrenowanym modelem?

Gdy sieć neuronowa osiąga dobre wyniki na danych testowych, trening zostaje zakończony. Wagi i biasy wszystkich neuronów są zapisywane do pliku, tworząc **gotowy model**.

Od tego momentu model nie potrzebuje już danych treningowych ani procesu uczenia. Jest gotowy do użycia, a jego działanie nazywamy **inferencją**. Dane wejściowe przechodzą przez sieć, która zwraca wynik, ale **wagi się nie zmieniają** – sieć już się nie uczy.



Made with GAMMA



Różnorodność architektur sieci neuronowych

Świat sieci neuronowych jest niezwykle bogaty i różnorodny. Istnieje wiele typów architektur, z których każda została zaprojektowana do rozwiązywania konkretnych rodzajów problemów. Wybór odpowiedniej architektury jest kluczowy dla efektywności modelu.

Sieci "Feedforward" (MLP)

Podstawowa architektura. Każda warstwa łączy się tylko z następną. Idealne do prostych zadań klasyfikacji i regresji.

Konwolucyjne (CNN)

Specjalizują się w przetwarzaniu obrazów i wideo. Wykorzystują filtry do wykrywania wzorców i cech w danych wizualnych.

Rekurencyjne (RNN/LSTM)

Zaprojektowane do pracy z danymi sekwencyjnymi, takimi jak tekst, mowa czy szeregi czasowe. Mają "pamięć" o poprzednich krokach.

Transformery

Nowoczesna architektura dominująca w przetwarzaniu języka naturalnego (NLP). Używają mechanizmu uwagi (attention) do modelowania zależności na długich sekwencjach.

Ta różnorodność pozwala na dostosowanie sieci neuronowych do szerokiego zakresu wyzwań, od rozpoznawania obiektów na zdjęciach, przez generowanie tekstu, aż po przewidywanie trendów rynkowych.

Made with GAMMA

Typy sieci neuronowych

Sieć, którą opisywaliśmy w tej prezentacji, to MLP. To dobry punkt startowy, ale w praktyce różne zadania wymagają różnych architektur. Poniżej przedstawiamy kluczowe typy.



Sieci MLP (Feedforward)

Podstawowa architektura, gdzie każdy neuron łączy się z każdym w następnej warstwie. Dobre do prostych zadań klasyfikacji i regresji, ale rzadko stosowane bezpośrednio do złożonych danych jak obrazy czy tekst.



Sieci Konwolucyjne (CNN)

Wykorzystują małe "okna" (filtry) do wykrywania lokalnych wzorców (krawędzi, kształtów) w obrazach i wideo. Niezastąpione w rozpoznawaniu obiektów, np. w Face ID.



Sieci Rekurencyjne (RNN)

Przetwarzają dane sekwencyjne, gdzie kolejność ma znaczenie (tekst, mowa, szeregi czasowe). Posiadają "pamięć" o poprzednich elementach, co pozwala im rozumieć kontekst w długich sekwencjach.



Architektura Transformer

Rewolucyjne w NLP (przetwarzanie języka naturalnego). Analizują wszystkie elementy sekwencji jednocześnie, oceniając ich wzajemne powiązania za pomocą mechanizmu uwagi. Podstawa modeli takich jak ChatGPT i Google Translate.

Wniosek jest jasny: architektura sieci dobierana jest ściśle do rodzaju zadania, które ma rozwiązać.

Made with GAMMA